原生 3DGS 引擎架构与性能报告

Windows / Android / Web / Cloud | 技术预览与实测证据 | 2026-10-04

本报告解释四个平台的实际引擎结构、核心技术栈、资源边界和已验证的性能优化，并整理 Windows / Web 与 SparkJS 的模型加载和计算阶段对照。架构图按平台独立绘制；性能表由原始 JSON 与基准日志生成，完整模型、格式、点数与 SHA 可追溯。

平台	计算位置 / 图形接口	交付与当前状态
Windows	本地 CPU + D3D12 / HLSL	C++20 SDK + WinUI 3；大场景与 GPU 阶段已实测
Android	本地 Service + Vulkan / SPIR-V	NDK C ABI + Kotlin AAR；Adreno 735/750 技术预览
Web	Worker / WASM + WebGPU / WGSL	ESM SDK 0.2.2-preview.1；DOM / React / Vue 可选入口
Cloud	服务端 C++ / CUDA / CUB	Go / SQLite / 缓存 + WinUI 图像客户端；API v3

本报告的新增测量

Windows：7 个模型，60 帧预热 + 120 帧采样，每模型 3 个独立进程；保留 SH3、stride=1。Web / Spark：6 个同文件模型、12 组结果，每组 30 帧预热 + 120 个相机姿态 × 3 轮；另做 18 个固定视角的图像比较。模型范围从 170,799 到 22,480,361 点；Web 全量加载附录覆盖全部 38 个 PLY/SPZ。

结论边界：Web 首次加载在本次六组中均慢于 Spark；本帧完成墙钟时间较小，但包含不同同步与 timer 观察开销，不能写成物理 FPS 胜出。Windows GPU 阶段与 Spark WebGL query 范围不同。391 万点新样本的前景 SSIM 最低 0.9865，不能声明全套等画质验收通过。

源码参考：d088902bcc464ef7bea1fca857f2b7cd3f10836c。Windows 使用已有 Release 二进制，本报告记录其 SHA 和修改时间，不声称本次重新构建了原生引擎。Web 运行当前源码；已有 38 模型/最大模型数据沿用 2026-10-04 发布验证，未冒充新增重复测量。

阅读索引与结论导航

先看架构，再按计时范围阅读性能；完整数据与复现入口位于附录

部分	内容	主要证据
01 / 口径与边界	共享模块、线程与所有权；公平比较条件	S01/S02/S05/S12/S19
02 / 四个平台	各平台独立架构图、目录映射、技术栈、性能细节	S01/S06/S09/S12
03 / Windows	7 模型加载/上传/GPU阶段；与 Spark 诊断并列	S03/S04/S05/S16
04 / Web	六模型首帧、完成帧、阶段、尾部；18 视角质量	S16/S17/S19
05 / 大模型与优化	2248 万点完整加载、GPU瓶颈、受控消融	S13/S14/S15/S21
06 / 验收与方向	测试覆盖、已知薄弱点、改进优先级	S07/S08/S11/S13/S22
附录 / 全数据	38 模型阶段表、文件SHA、复现与证据索引	S04/S14/S16/S20

五项可直接使用的判断

1. 四端遵循相同的格式/场景/渲染/引擎分层，但图形后端并非同一套 API：D3D12、Vulkan、WebGPU、CUDA 分别负责本地或服务端 GPU。2. 当前 Cloud 把图像传回客户端；Web 云图像客户端尚未实现。3. Windows 与 Web 最大模型均保留完整 SH3 点集合，本机有实际容量证据。

4. Windows 的解码/上传路径比浏览器 OPFS 链路更短，但当前 Windows 表不包含首帧、设备初始化与 Present；不能直接用其阶段和对比 Spark 的完整首帧。5. Spark 的 Rust/WASM、压缩数据与 Worker 排序具有值得借鉴的流式和局部性设计；语言标签本身不能解释端到端差异。

01 / 性能指标与可比性

相同模型名、相同分辨率，并不自动意味着同一成本或同一画质

指标	起止边界	允许 / 不允许的解释
Windows load_ms	make_model_loader()->load 的完整等待	包含进程/读取/解压/规范化/验证；不是单独解码 kernel
Windows upload_ms	UploadTransaction 启动至 ready	包含 packing/copy/fence；不含设备初始化和首帧
Windows GPU stages	D3D12 四时间戳，强制全量 project/sort/draw	60+120 ×3，固定 fit 相机、无 Present；不是屏幕帧率
Web firstFrameMs	open 至首帧 GPU完成 / Spark 首排序+draw+finish	同一 Web 入口和模型；每组仅一次加载，非三轮加载统计
Web completedMs	每个相机姿态更新至本帧完成与 timer 可用	含 Worker/update/readPause/IPC/同步等待；不测扫描显示
Web GPU stages	WebGPU projection / radix / draw timestamps	同一个 gpuFrameId；约 65.5 微秒量化
Spark gpuMs / updateMs	同步 WebGL query / spark.update 墙钟	前者不含异步Worker排序；后者不是纯排序 kernel
38 模型 stage wall	Loading 各 stage 状态切换	CPU、WASM拷贝、OPFS I/O均可在stage中；不能当纯CPU时间

统计口径：Windows 表为三轮每轮样本中位数再取中位数；Web 沿用 runner 的 p50/p95 定义，再报告三轮中位或范围。p50/p95 各阶段分别统计，阶段 p50 之和不一定等于总帧 p50。磁盘/OS/浏览器缓存没有清空，所有加载结果都不是“冷缓存性能”声明。

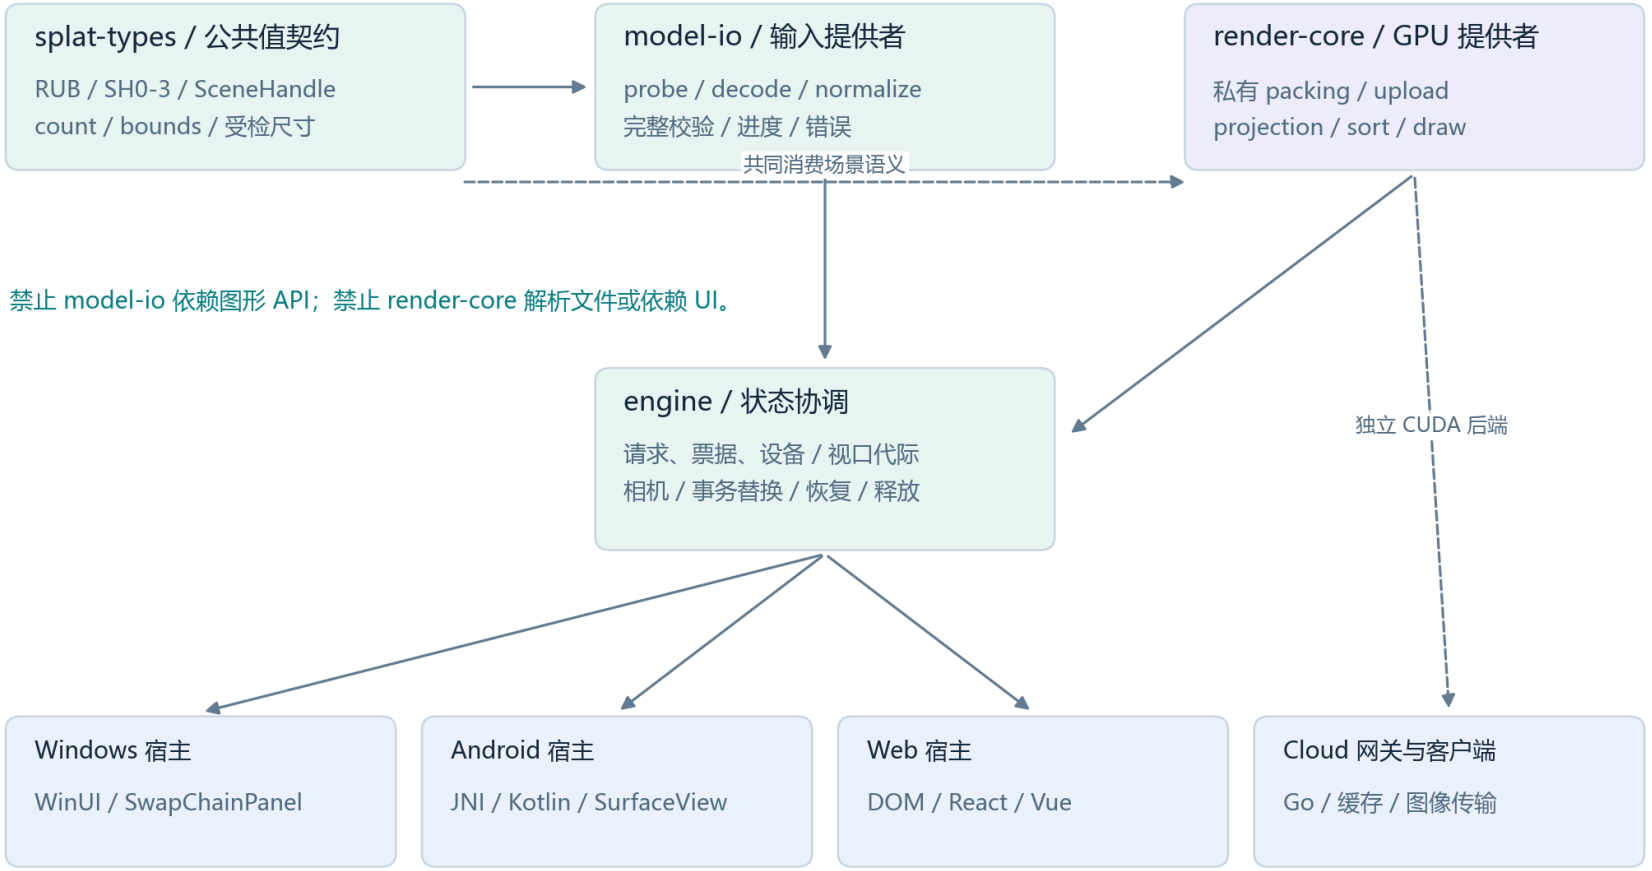
测试环境：Windows x64、32GB RAM、NVIDIA RTX3080 10GiB、驱动616.92；Web 使用 Edge154.0.4258.53、1920×1080、DPR1、SH3、完整点集合、径向排序、无LoD。Spark2.3.1 / Three0.180.0，extSplats / accumExtSplats；固定参数包括 FOV60°、3σ、minAlpha1/255、preBlur0.3、maxRadius4096。Windows固定相机与Web运动姿态不同，因此只作诊断并列。[S04/S05/S16/S19]

02 / 模块依赖与资源边界

架构共性：可替换宿主、不可变场景、独立解码与渲染提供者

主要模块 / 依赖与资源边界

跨平台共享数学和格式语义；图形后端、宿主和传输各自独立



Cloud 的 CUDA worker 是独立后端实现，不能按图理解为复用桌面 IEngine 实例。

图1：模块依赖图。Cloud 复用数学/格式语义，CUDA worker 和网关是独立实现，不是桌面 IEngine 的网络包装。

03 / Windows 引擎架构

已实现路径；C++20 / Direct3D12 / HLSL / WinUI3

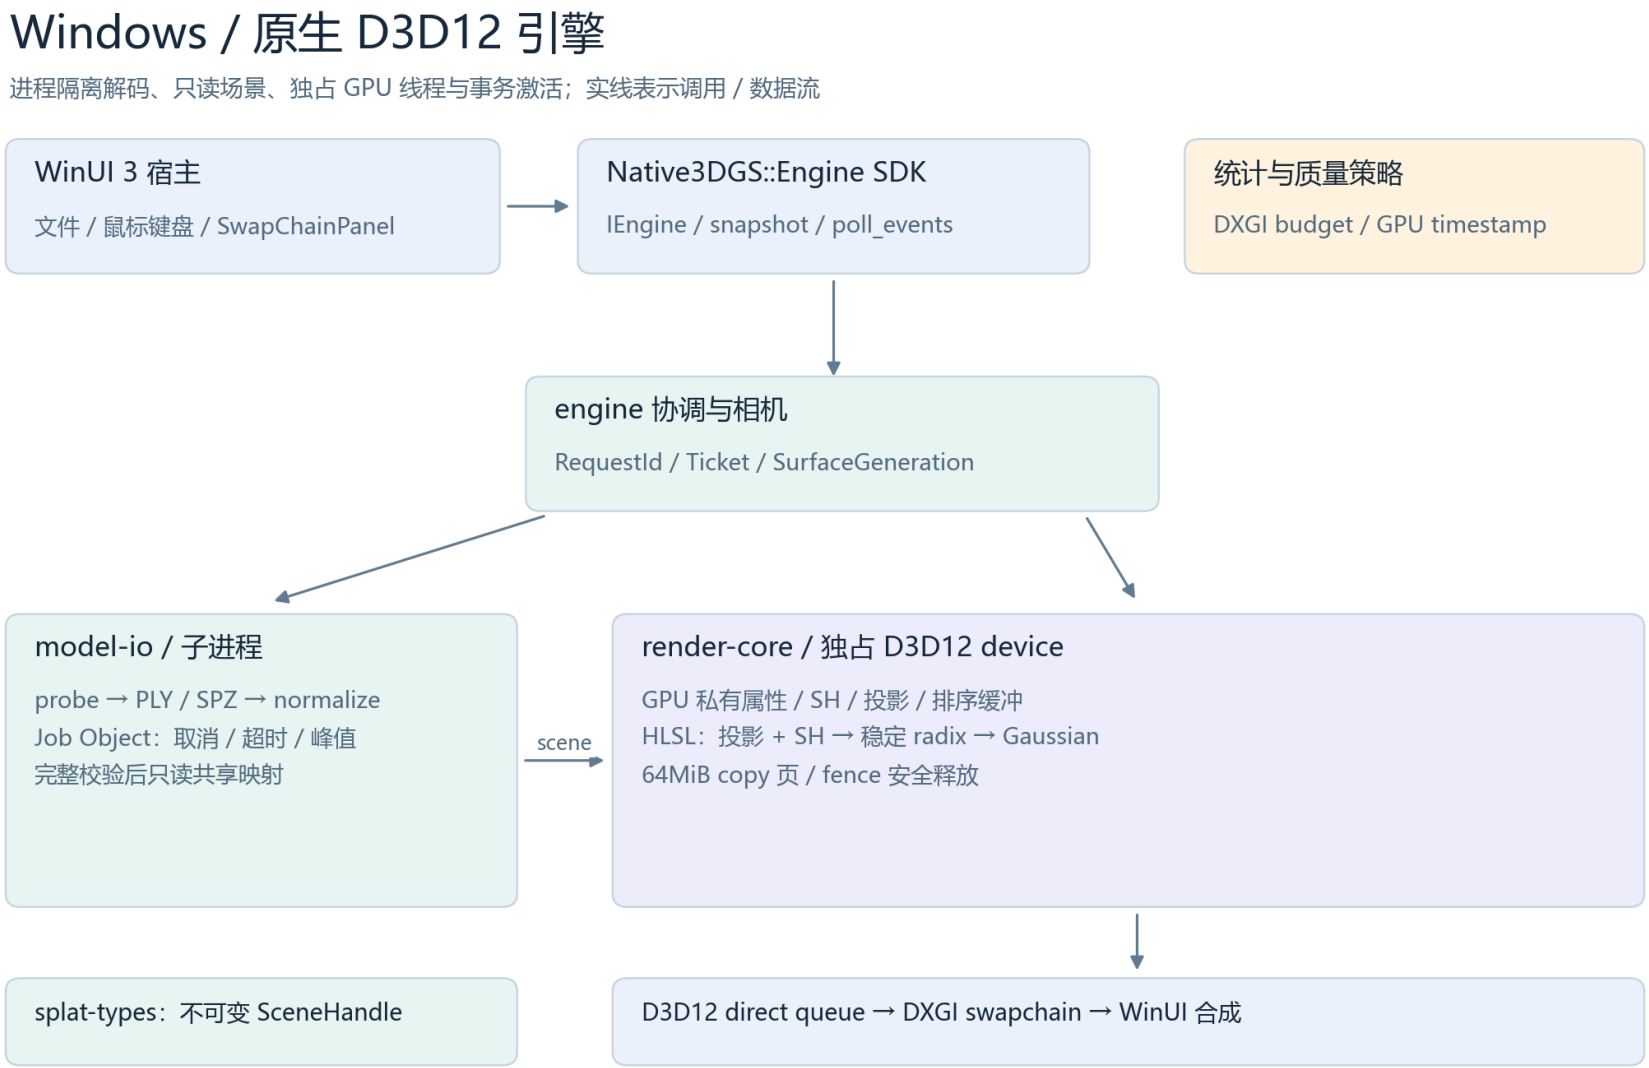


图2：Windows 平台独立架构。解码隔离进程发布只读场景，renderer 独占 device/queue；宿主按 generation 绑定交换链。[S01/S02]

Windows / 主要模块、线程与性能机制

原生 SDK 与 WinUI 宿主解耦；容量优化和帧时间优化分别记录

模块 / 源码	职责与数据结构	关键机制
include/splat-types + src/model-io	只读 SceneHandle；PLY/SPZ探测、解码、RUB规范化、SH校验	Job Object 隔离子进程；取消/超时/峰值；PLY约4MiB读取
src/render-core/scene	属性/SH私有缓冲、分块上传事务	64MiB copy页；真实DXGI local/non-local/UMA预算；新旧峰值
src/render-core/passes	投影+SH、稳定 radix、Gaussian quad透明绘制	FidelityFX Parallel Sort；4-bit ×8 pass；上限16000组
src/engine + include/native3dgs	协调线程、double世界相机、相对float32 GPU、请求/票据/代际	首帧Present后事务激活；事件队列与快照；设备解绑确认
GUI/	WinUI3 / Windows App SDK1.8 / SwapChainPanel	不解析模型；surface_generation；输入与SDK状态消费

已保留的性能改进

上传页4→64MiB使大模型上传从约20.3秒降至约1.5秒。排序工作组上限800→16000使2248万点排序约10.1→7.8ms。SH动态循环固定展开保持原累加顺序，大模型投影约15.1→10.3ms。6次顶点调用改为4顶点三角带，绘制约16.4→15.34ms；当时force完整GPU帧约33.4-33.8ms。单轮结果与本次三轮数值不能视为同一个实验。[S03]

ProjectedEllipse 48→40字节减少最大场景约180MB投影缓冲，是容量收益，未证明独立帧时间收益。128MiB copy页、四元数矩阵展开、行列式代数改写和3顶点覆盖三角形均未达到可靠或全面收益而撤回。静止相机复用排序，cached路径只代表绘制，不与force全排序帧混合。

Windows 允许显式质量缓解：先降GPU SH，再按2/4/8/16索引间隔显示；必须报告实际点数/SH。当前测量使用SH3、stride1，所有降质数据排除。Web 当前策略则在资源不足时明确拒绝，不自动抽点或降SH。

04 / Android 引擎架构

已实现路径；Kotlin / JNI / C ABI / Vulkan1.1 / GLSL-SPIR-V

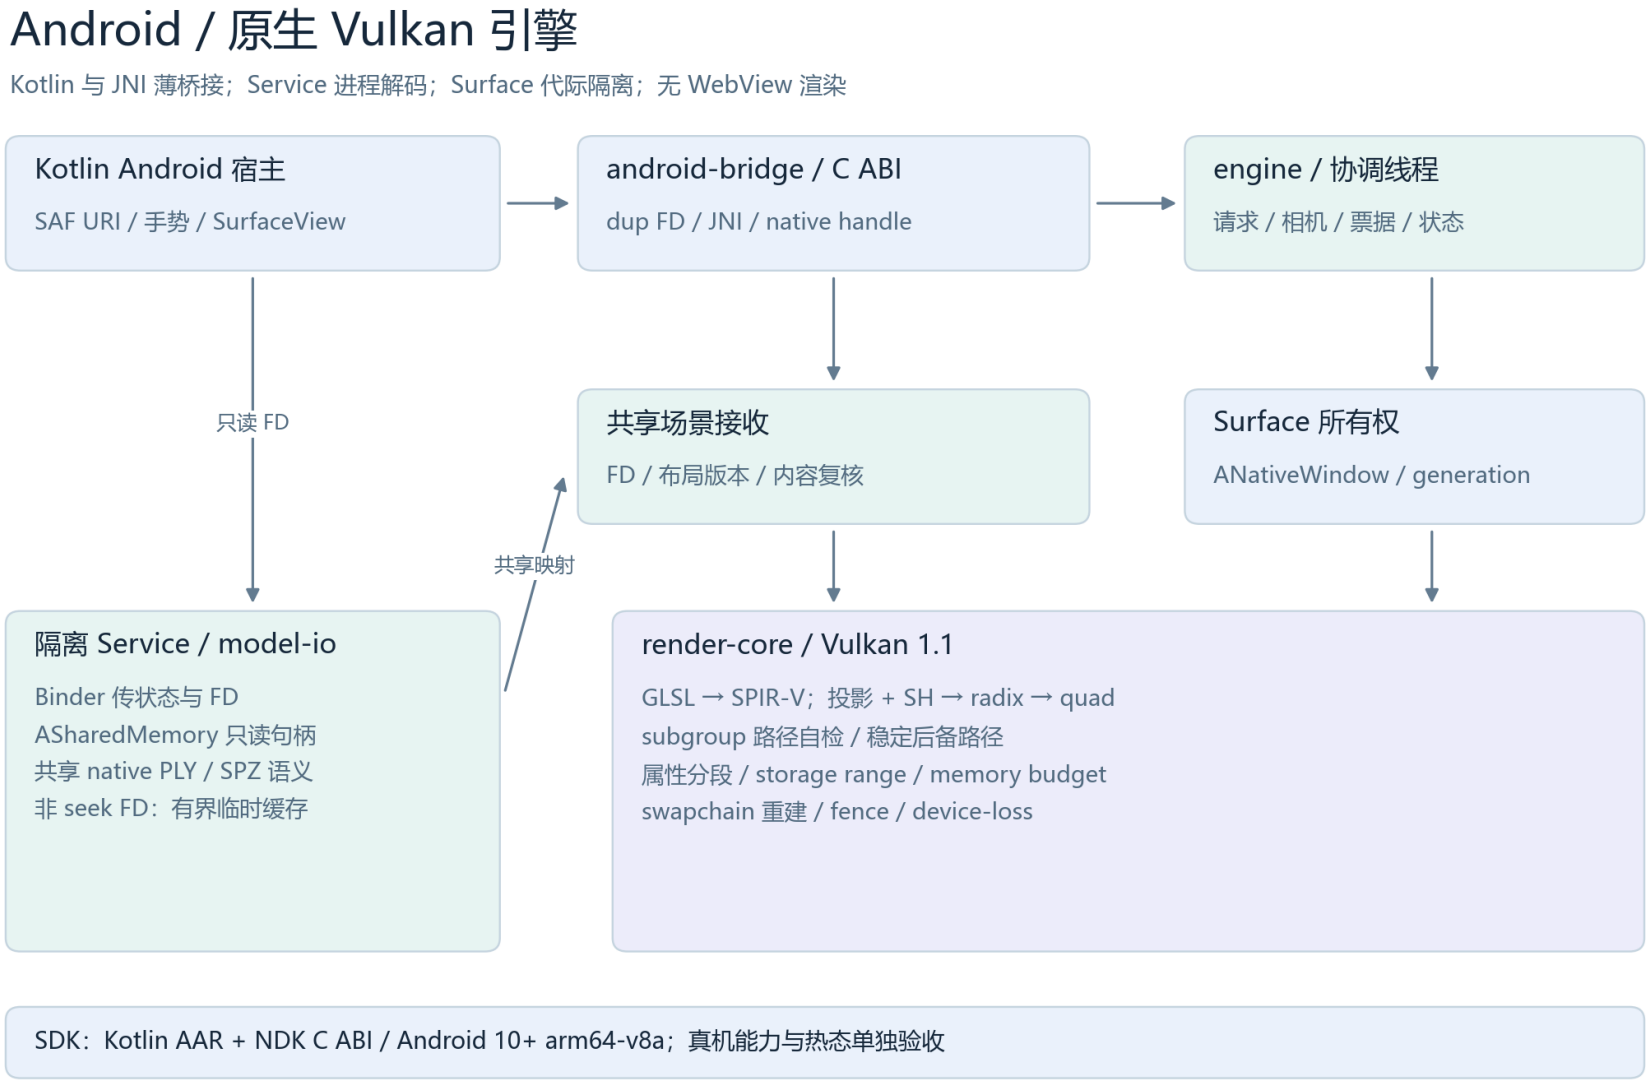


图3：Android 平台独立架构。Binder只传FD/状态，完整模型驻共享映射与GPU，UI不承载逐点大数组。[S06/S07]

Android / 模块与移动设备边界

不同设备的 storage range、热状态和 subgroup 能力必须实机验证

模块	职责与交付	实现细节与限制
model-io Service	复用 native PLY/SPZ数学；只读FD和ASharedMemory	非seek有界临时文件；Binder死亡/超时；完整布局与内容复核
render-core Vulkan	SceneRenderer / stable GPU sort / Gaussian+SH	storage range分段；subgroup自检+后备；fence后读timestamp
engine	协调、相机、待命/活动scene、Surface代际	提交成功后激活；旧generation不能复活；零Surface暂停
android-bridge / SDK	C ABI、JNI、Kotlin AAR、Native3dgsEngine	SurfaceView / ANativeWindow引用；宿主协程关闭，UI不长等fence
GUI / 构建工具	Kotlin2.0.21 / JDK21 / NDK27.2 / SDK35	API29+、arm64-v8a技术预览；非WebView后端

真机性能支持什么结论

Adreno750平板：1,888,950点SPZ，30秒预热+60秒采样。基线三轮Present-call中位值的中位数78.12ms，最终subgroup路径56.55ms；GPU排序均值三轮中位34.98→17.84ms。仅最终第1轮全程thermal0，后两轮存在thermal3，不能称严格等热态性能验收。实测显示间隔50ms，未达到33.3ms/30FPS移动门槛。[S08]

Juyuan 2,670,017点 SH3：设备maxStorageBufferRange=128MiB；属性拆成128MiB与约15.3MB两段，SPZ和PLY完整上传首帧成功。该实现最多两段；投影buffer仍把此设备上限限制为2,796,202点，且需足够compute storage descriptors。没有把安卓的大场景能力外推到Web的2248万点模型。

这些 Android 数据用于说明架构的实际动机，不是与 SparkJS 的同机比较。模拟器不能证明移动GPU速度；完整SSIM、热稳与跨驱动门槛仍未关闭。

05 / Web 引擎架构

实际交付版本0.2.2-preview.1；框架可选，核心API统一

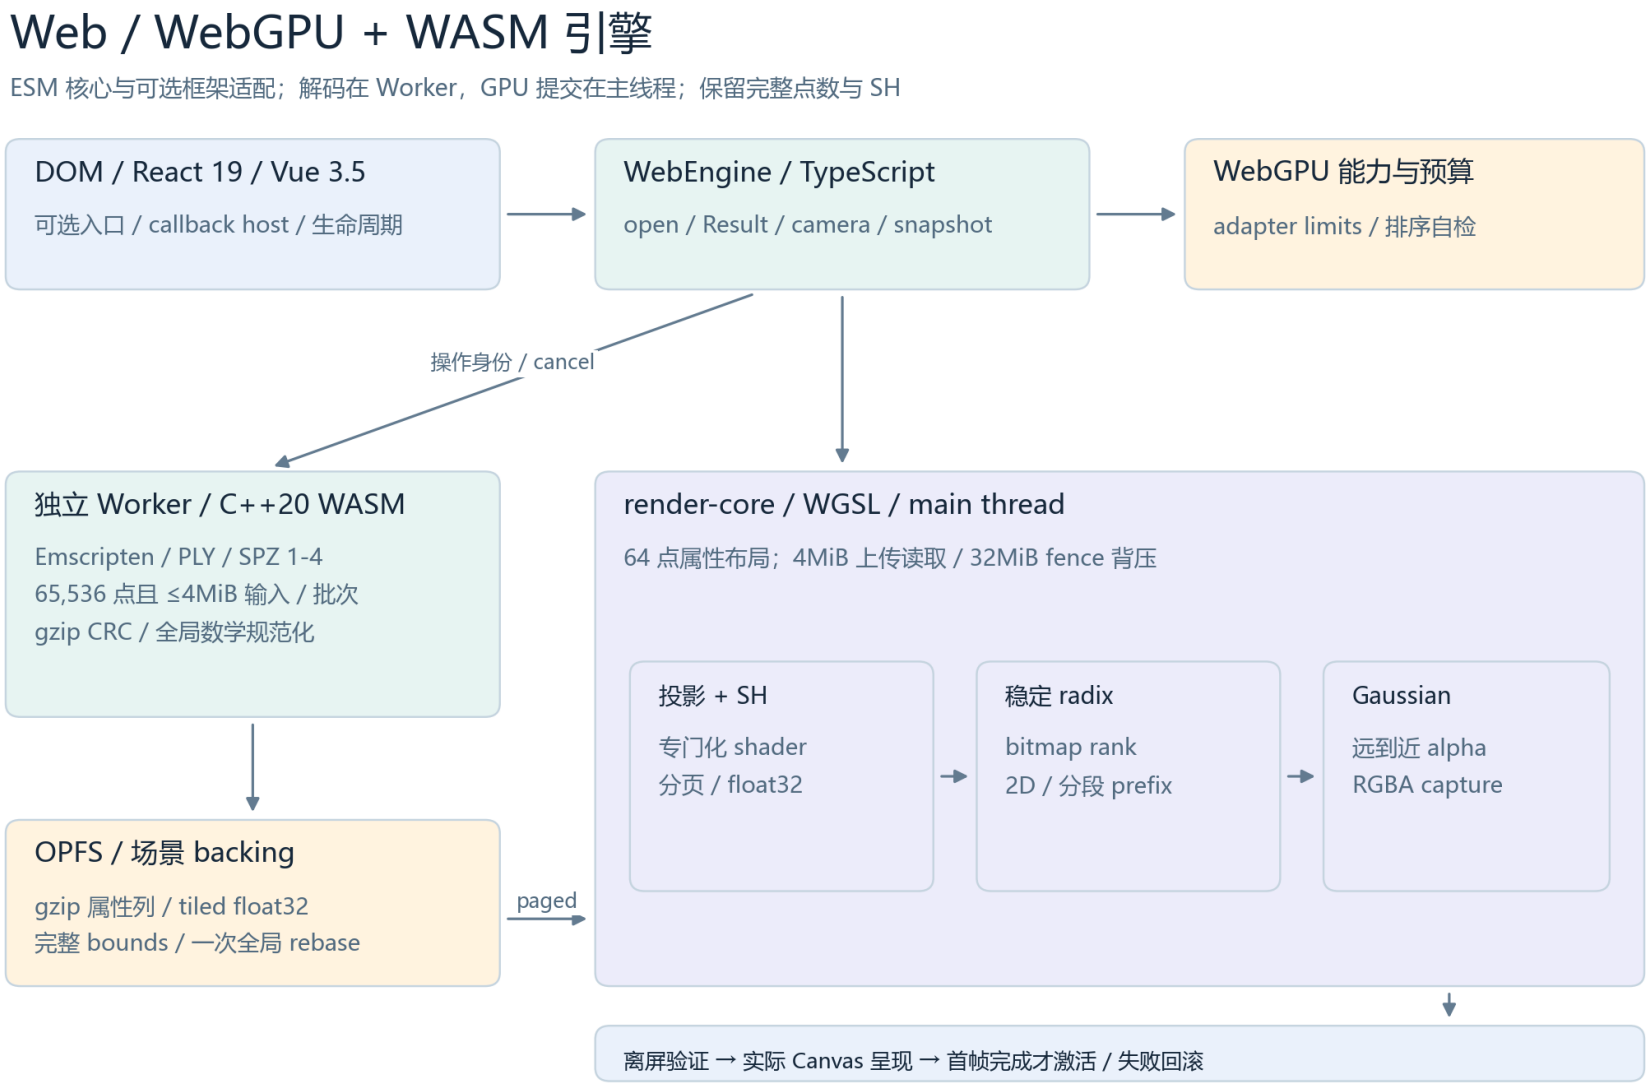


图4：Web 平台独立架构。解码Worker与主线程WebGPU分离；tiled backing分页进入同一全局稳定排序。[S12/S13]

Web / WASM、OPFS 与 GPU 热路径

容量与取消可靠性优先；保留所有点、float32和SH0-3

模块 / 技术栈	结构与职责	性能 / 可维护性细节
src/splat-types + model-io	Result、预算、readonly scene；Worker + C++20/WASM	Emscripten6.0.11；PLY/SPZ1-4；共享normalize语义
native + streaming + backing	批次decode/pack、gzip校验、OPFS持久backing	≤65536点且输入≤4MiB；并读六列；CRC/长度；一次全局rebase
src/render-core	WGSL投影/SH、4-bit稳定radix、透明绘制	64点tiled float32；bitmap/popcount rank；2D dispatch/分段prefix
src/engine	load latest-wins；相机；离屏及Canvas候选验证	旧场景失败回滚；deadline；可移除lost订阅；GPU预算统一
src/web-adapters + react/vue	DOM生命周期；可选ESM子路径；订阅与host绑定	React19.3、Vue3.5.43；StrictMode/条件host/SSR消费
构建 / 测试 / 包	Node24.14、pnpm11.4、TS7.0.2、Vite8.3.2	Vitest5 / Playwright1.63 / Biome2.5；锁定依赖/资产SHA

大PLY与gzip SPZ v1-3用OPFS规避整场景WASM32峰值：下载到临时文件，SPZ解压列属性到磁盘，再小批次native规范化，写tiled backing，一次全局rebase，4MiB读取上传，累计32MiB等待fence。64点对齐末页padding仅影响存储；逻辑count、投影、排序、绘制均不包含padding。SPZ v4仍为有界内存路径。[S12/S13]

默认input/scene/GPU各8GiB、CPU512MiB、deadline600000ms；这些是策略预算，不是实际可用内存。最大GPU场景6,575,533,896B，backing5,305,370,624B。CPU residentBytes=0表示没有保留整份ArrayBuffer，不能解释为RSS/缓存为0。OPFS删除最多等5秒，失败仍释放GPU，在Stopped快照保留StorageCleanup诊断。

GPU执行仍在主线程；渲染Worker、SIMD/pthreads、LoD、云客户端、WebXR、通用Three场景混合均未实现。现代技术栈版本不等于跨浏览器验证；当前实测仅Windows/Edge/NVIDIA。

06 / Cloud 引擎架构

实际API v3图像链路；服务端完整渲染，客户端只解码与显示

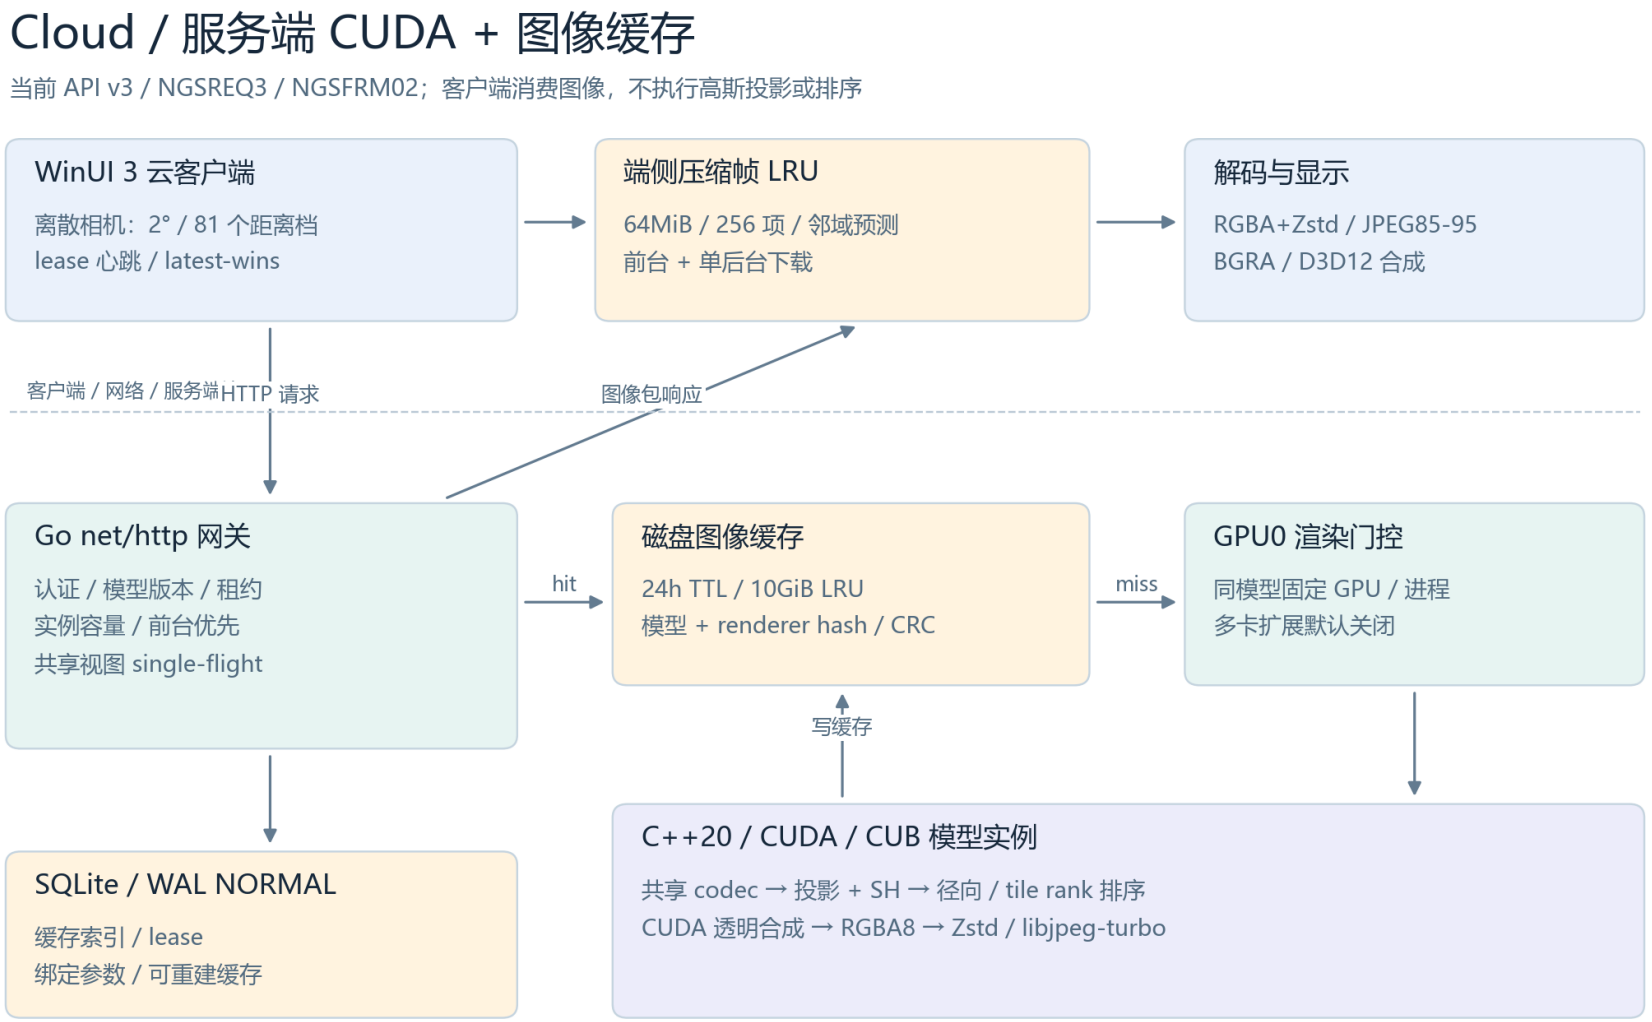


图5：Cloud 平台独立架构。缓存hit可以不启动GPU实例；相同模型/视图共享缺失渲染。ProjectedSplats属于退役原型。[S09/S11]

Cloud / 实例、缓存和传输机制

单模型单进程、固定GPU；前台优先与缓存是主要交互性能策略

层	核心技术栈 / 模块	性能与资源机制
原生渲染实例	C++20 / CUDA13.0.88 / CUB；cuda_renderer.cu	完整SH；径向/tile-rank排序；CUDA透明合成；无窗口/EGL
服务网关	Go1.27.1 / net/http / single-flight	同视图缺失合并；每模型固定进程/GPU；默认最多4实例
元数据和图片缓存	SQLite3.37.2 WAL NORMAL；磁盘原子rename	24h TTL；10GiB/100000项LRU；模型/renderer hash；CRC/SHA
图像协议 / 编码	NGSREQ3 / NGSFRM02；Zstd1 / libjpeg-turbo	RGBA raw fallback；JPEG85-95；不用传原始splat数组
WindowsClient	WinUI3 / 异步WinHTTP / D3D12显示	64MiB/256压缩包；前台+单后台；显示才解码；latest-wins

离散相机为2°方位/极角网格及81个对数距离档；缓存key包含模型内容、renderer版本、位置、朝向、尺寸、质量。当前默认JPEG85，邻域预测每方向5/10/15档；租约120秒，10秒心跳，实例空闲宽限300秒。已有GPU0实例可复用，缓存hit不需要重载模型；网络命中、本地命中和GPU缺失渲染是不同成本。[S09/S11]

历史API v3缓存基准 / 267万点 /1080pRGBA	miss p50 / p95	hit p50 / p95
Windows→映射入口，逐帧同步持久化	220.656 / 304.929ms	106.261 / 135.139ms
同相机，WAL NORMAL + 可重建缓存	74.182 / 84.527ms	32.849 / 46.699ms
服务器回环，同一优化链路	34.251 / 40.810ms	2.440 / 2.808ms

上表来自S10的20miss+20hit短基准，是读完HTTP响应的墙钟，不含WinUI解码/物理呈现，也不是本次0.2.2新测量。当前设备报告RTX4090/49140MiB，4卡只启GPU0；不把历史四卡吞吐写成当前架构扩展验收。公网TLS/RBAC、WAN长稳和全38模型云端覆盖仍未验收。

07 / 四端计算流水线

shared semantics 不代表相同存储、相同调度或相同统计范围

计算阶段 / 数据布局与性能收益

格式读取、规范化和 GPU 帧分别计时；每个平台保留自己的执行与同步模型

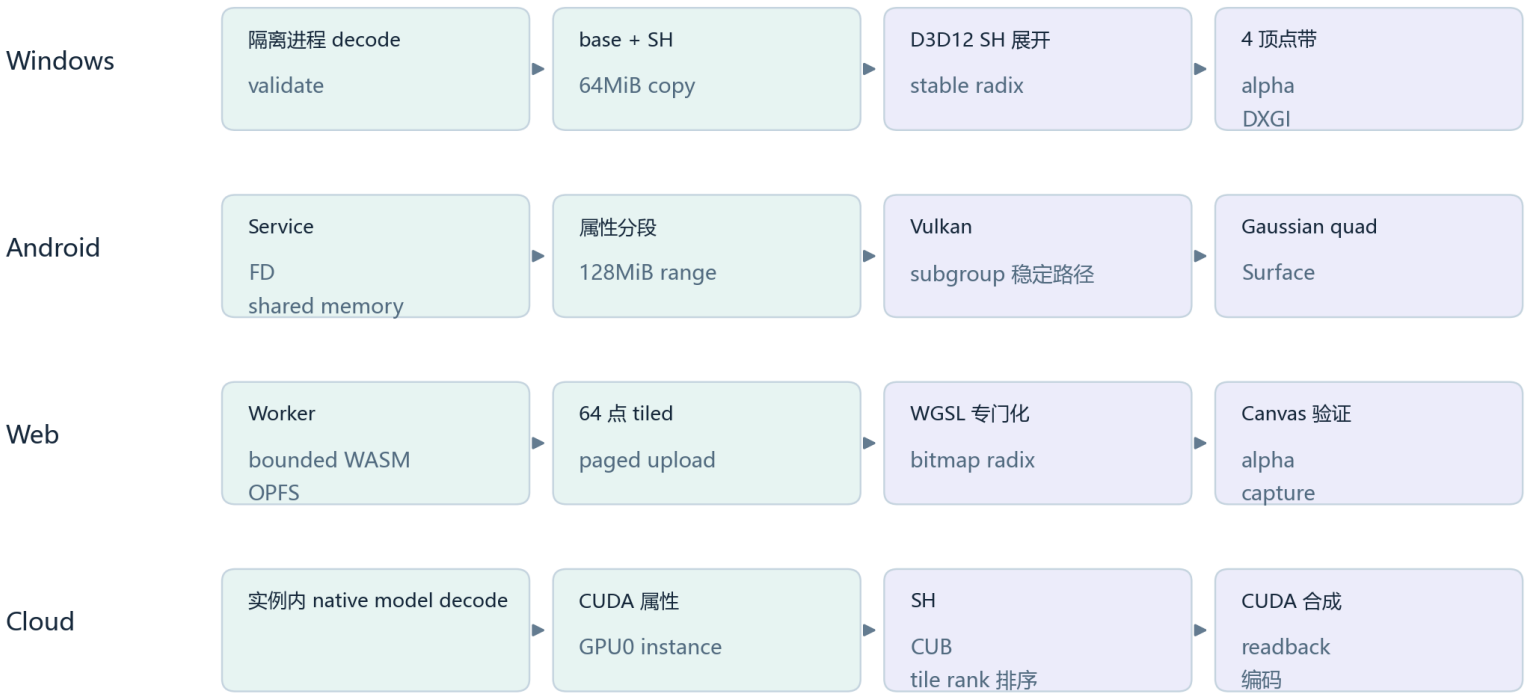


图6：主要模块内部的计算顺序与性能机制。File decode、GPU帧和云HTTP缓存命中必须分别解释。

共同顺序：输入预检 → 解码/规范化 → GPU packing/upload → 相机相关投影/SH → 稳定排序 → 透明合成。Cloud额外包含tile任务、readback、编码/缓存/传输；Web额外包含WASM边界拷贝与OPFS多遍I/O。

08 / Windows：七模型加载与 GPU 阶段

本次新增诊断；单位ms；GPU列为三轮每轮p50再取中位数 [S04/S05]

模型	点数	读取/解码/验证	GPU上传	投影+SH	排序	绘制	GPU总帧
changjin_v1.ply	170,799	91.6	30.9	0.094	0.138	0.206	0.439
shengyi_v1.ply	804,758	487.3	67.8	0.380	0.331	0.566	1.277
shengyi_v1.spz	804,758	711.6	64.8	0.380	0.328	0.561	1.270
tumu_v1.ply	1,248,730	694.9	104.4	0.578	0.465	0.864	1.906
tumu_v1.spz	1,248,730	1,075.5	115.5	0.579	0.464	0.864	1.907
zhihuizhimen.ply	3,914,609	1,953.6	275.7	1.779	1.263	2.671	5.720
jiulonghu_v1.ply	22,480,361	10,506.7	1,475.4	10.470	8.091	16.009	34.633

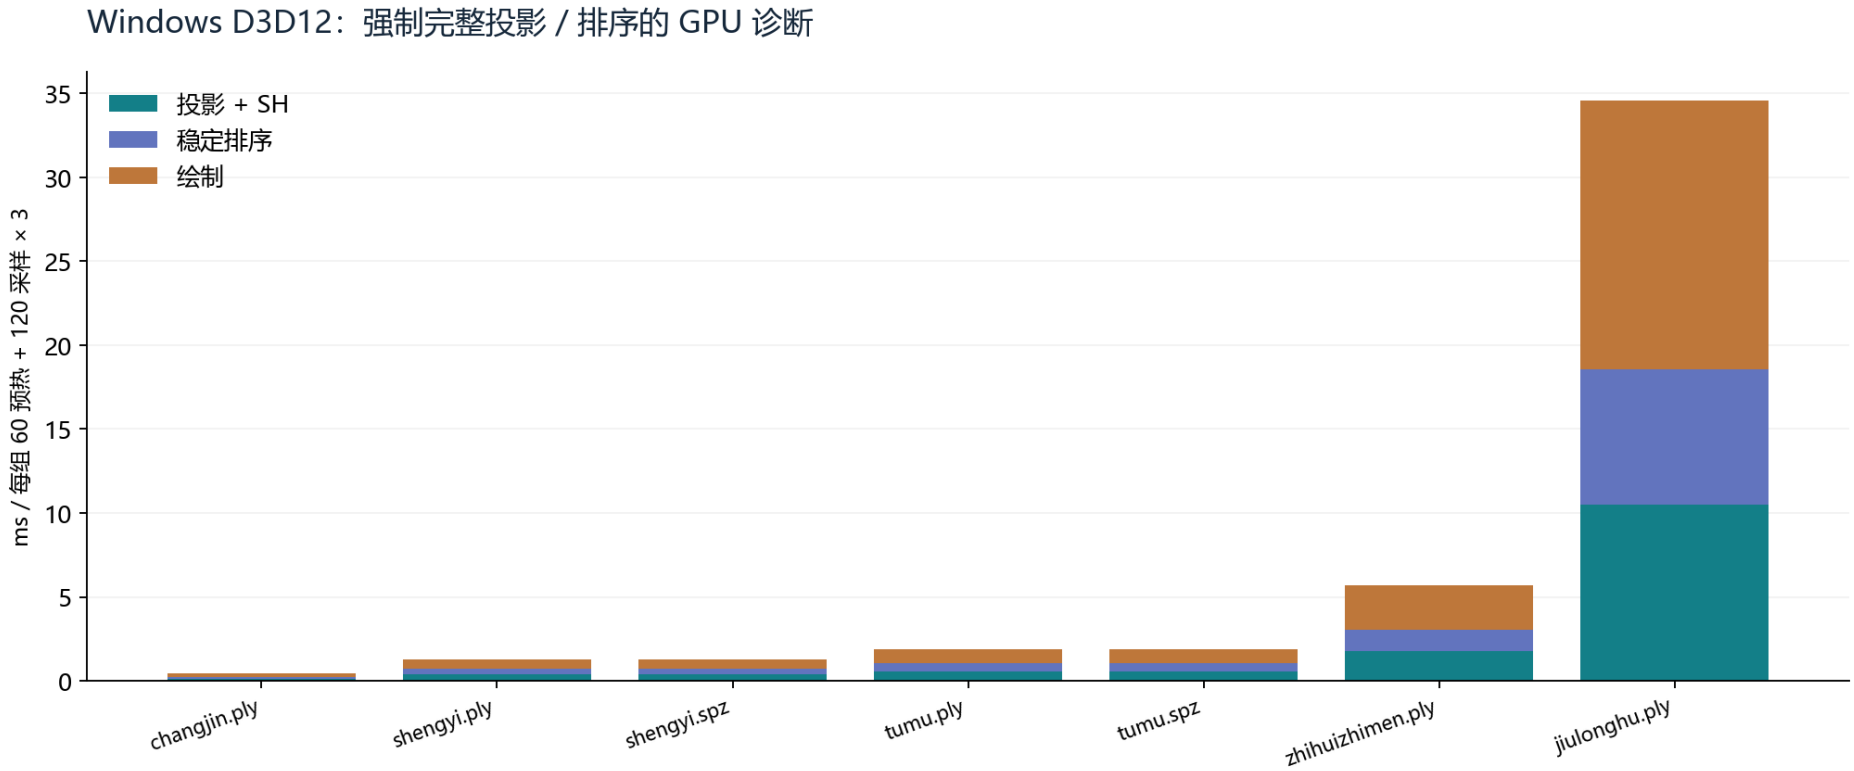
每个模型3个独立SceneBench进程，60预热+120采样，固定fit相机，force每帧重投影/重排，SH3/stride1/1920×1080。所有进程正常退出，计时样本120/轮；模型SHA和点数与manifest一致。Windows loader直接访问本地文件；未逐项分离纯文件读取、SPZ解压、属性规范化和验证。

同一规模的格式差异集中在CPU侧：shengyi PLY/SPZ约487/712ms；tumu PLY/SPZ约695/1076ms。GPU阶段相近，但两格式经SPZ量化后的源属性未必逐值相同。大PLY load约10.507秒、upload约1.475秒；GPU完整帧中位约34.633ms。阶段和约11.982秒不等于首个完成帧，因为还未包含device/pipeline/首帧设置。

二进制SHA-256：aa2da0d1708c50d433a297627c40b3e797953f0263574c4f271a6c4462610d04；修改时间UTC：2026-09-30T02:10:33.427041+00:00。本轮执行已有Release二进制，没有重新构建。日志和原始120帧数组已保留；依赖环境/时钟波动未做统计显著性检验。

Windows：规模增长与 GPU 热点

固定相机强制排序路径；保持完整 SH3 和点数



固定 fit 相机、SH3、stride1、1920×1080、无 Present；不能与 Web 运动轨迹或桌面呈现 FPS 混用。

图7：三阶段p50中位的堆叠，仅用于瓶颈分布；不是阶段之和的整帧p50统计。[S04]

最大模型约10.47ms投影、8.09ms排序、16.01ms绘制；绘制约占总帧46%，已不适合只围绕排序做优化。近景重叠、几何/像素成本、真实可见集合与压缩成本应分别消融。静止相机cached模式避开重投影与排序，不能替代用户运动时的force诊断。

09 / Windows、Web 与 Spark：加载对照

Windows列为两段已测墙钟的和；Web/Spark列均为各自首个完成帧

同一文件	输入MiB	点数	Windows decode+upload	Web首帧	Spark首帧
changjin_v1.ply	38.44	170,799	125.6	686.2	610.0
shengyi_v1.ply	181.13	804,758	564.9	2,164.8	1,151.9
shengyi_v1.spz	17.10	804,758	776.4	1,769.7	915.6
tumu_v1.ply	281.05	1,248,730	794.4	3,331.7	1,771.6
tumu_v1.spz	23.28	1,248,730	1,191.0	2,651.9	1,252.3
zhihuizhimen.ply	881.05	3,914,609	2,251.4	9,734.3	4,876.7

新测六组中，Web/Spark首帧：changjin约686/610ms；shengyi PLY约2165/1152ms、SPZ约1770/916ms；tumu PLY约3332/1772ms、SPZ约2652/1252ms；391万点PLY约9734/4877ms。Web首次加载约为Spark的1.12-2.12倍，当前加载薄弱点跨两种格式存在。首载每组仅一次，不能把比值当长期统计结论。

Windows decode+upload明显更短，但测量起止不等价：它不含GPU设备/管线创建、首帧/Present/WinUI合成；Spark包含URL加载、Rust/WASM初始化、解码/pack、上传、首排序和同步绘制。Windows与Spark之间不计算“整体快多少倍”。同一文件SHA可以核验输入相同，却不能消除进程、缓存、相机和同步机制差异。[S04/S05/S16/S19]

在Web/Spark首帧列使用loaded.firstFrameMs，没有使用loaded.ms；后者Spark额外含60次draw/next稳定过程，误用会系统性放大Spark加载时间。最大2248万点没有Spark同协议数据，报告不填估计值。

Windows / Spark：同模型渲染诊断并列

单位ms；三轮p50的中位值；相机与GPU query范围不同 [S04/S05/S16/S19]

同一文件	Windows投影	Windows排序	Windows绘制	Windows完整GPU	Spark同步GPU	Spark update墙钟
changjin_v1.ply	0.094	0.138	0.206	0.439	1.297	13.1
shengyi_v1.ply	0.380	0.331	0.566	1.277	3.587	24.5
shengyi_v1.spz	0.380	0.328	0.561	1.270	3.320	24.6
tumu_v1.ply	0.578	0.465	0.864	1.906	4.918	30.2
tumu_v1.spz	0.579	0.464	0.864	1.907	5.294	30.2
zhihuizhimen.ply	1.779	1.263	2.671	5.720	10.910	76.8

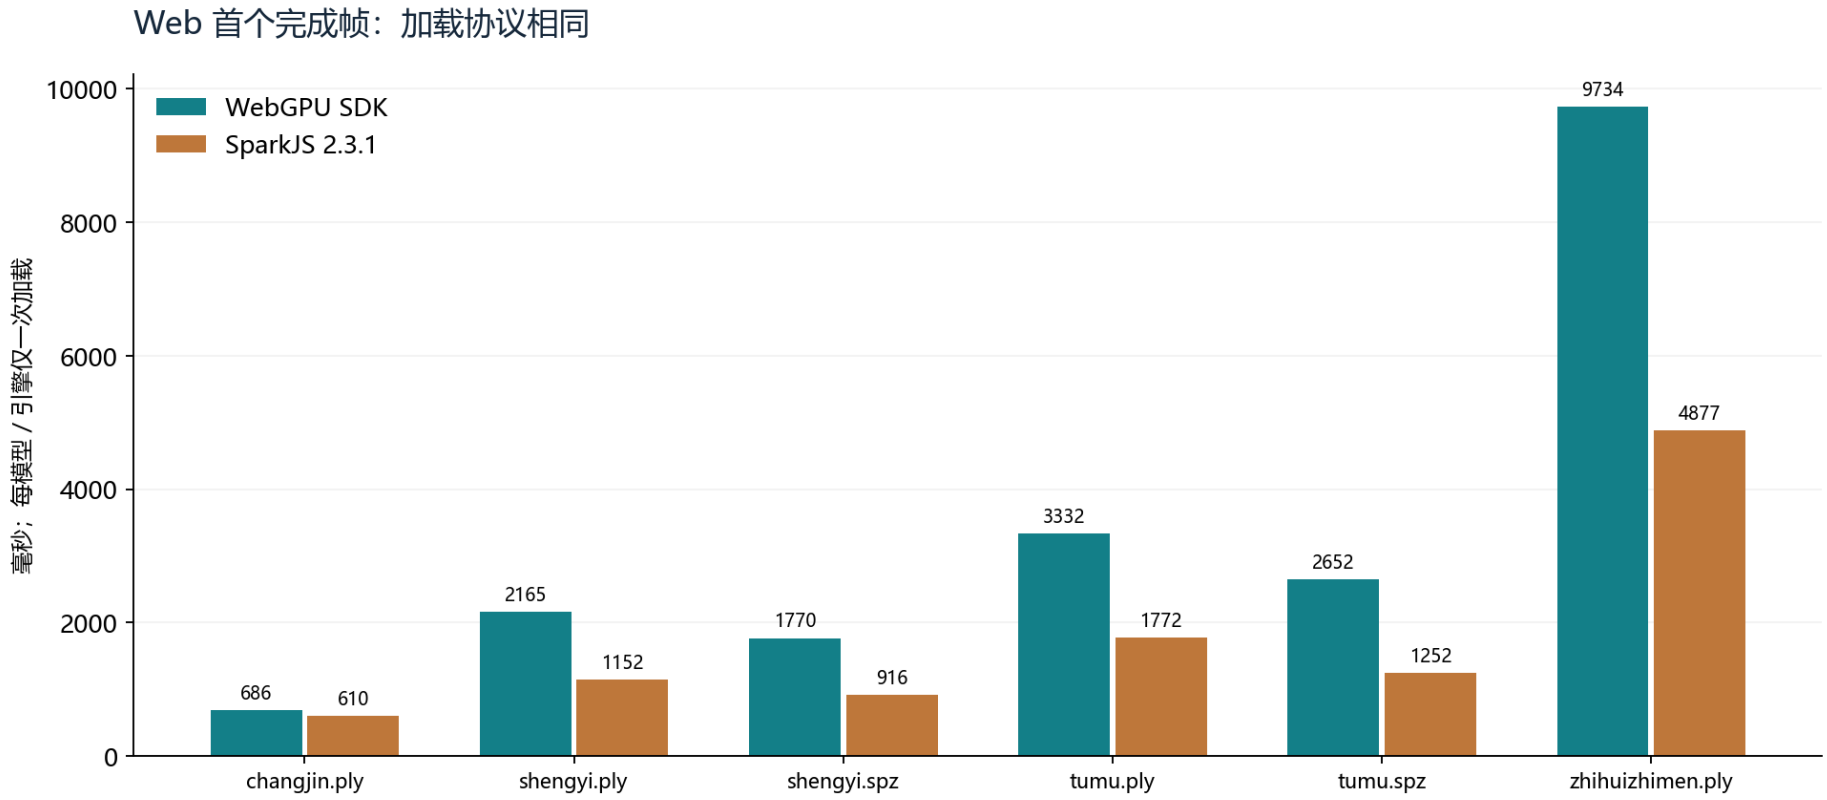
Windows三列来自固定fit相机、force全投影/排序、D3D12 GPU时间戳；Spark来自浏览器运动相机、等待当前相机排序、同步WebGL query。相同文件SHA、SH3、完整点数和1920×1080仅保证部分输入条件相同；相机可见分布、绘制工作与同步成本仍不相同。此表用于定位瓶颈，不计算引擎整体速度倍数。

Spark阶段	本轮采集状态	可使用的替代证据与限制
纯解码 / 规范化 / pack	未独立测量	首帧覆盖完整加载链路，不能用总首帧减法推算
投影 + SH	未独立测量	同步GPU query为合并范围，不能分摊成投影和绘制
纯Worker / WASM排序	未独立测量	update墙钟含读回、默认暂停、调度与等待
物理显示 / Present	未测	Windows GPU与Spark completed均不是实际显示帧率

本轮未取得Windows/Spark同相机图像质量对照，也未对最大2248万点模型运行Spark同协议测量。Windows内部回归测试与Web/Spark静态SSIM不能替代Windows/Spark的等画质验收。

Web / Spark：首帧加载图

同文件、相同浏览器、相同完成帧定义；各组单次加载



1920×1080 / 全点 / SH3。完成帧包含 Worker update、timer 观察和同步等待；不是物理显示 FPS。

图8：六组首个完成帧。浏览器/OS缓存未清空，不代表冷缓存；无LoD、全点SH3。[S16/S19]

10 / Web 与 Spark：完成帧墙钟

每组30预热+120相机姿态×3；本次12组均complete，failures为空

模型	Web p50 / 三轮范围	Spark p50 / 三轮范围	Web p95中位	Spark p95中位	Spark update p50
changjin_v1.ply	4.0 / 4.0-4.0	18.2 / 18.1-18.9	5.1	24.1	13.1
shengyi_v1.ply	3.9 / 3.9-4.0	35.0 / 34.0-35.0	6.0	39.1	24.5
shengyi_v1.spz	4.0 / 4.0-4.0	35.0 / 33.9-35.0	6.0	40.0	24.6
tumu_v1.ply	4.1 / 4.1-4.1	41.9 / 41.0-41.9	5.9	47.9	30.2
tumu_v1.spz	4.1 / 4.1-4.2	41.5 / 40.5-42.0	6.0	50.0	30.2
zhihuizhimen.ply	8.1 / 8.1-8.7	98.1 / 95.3-98.5	10.9	103.4	76.8

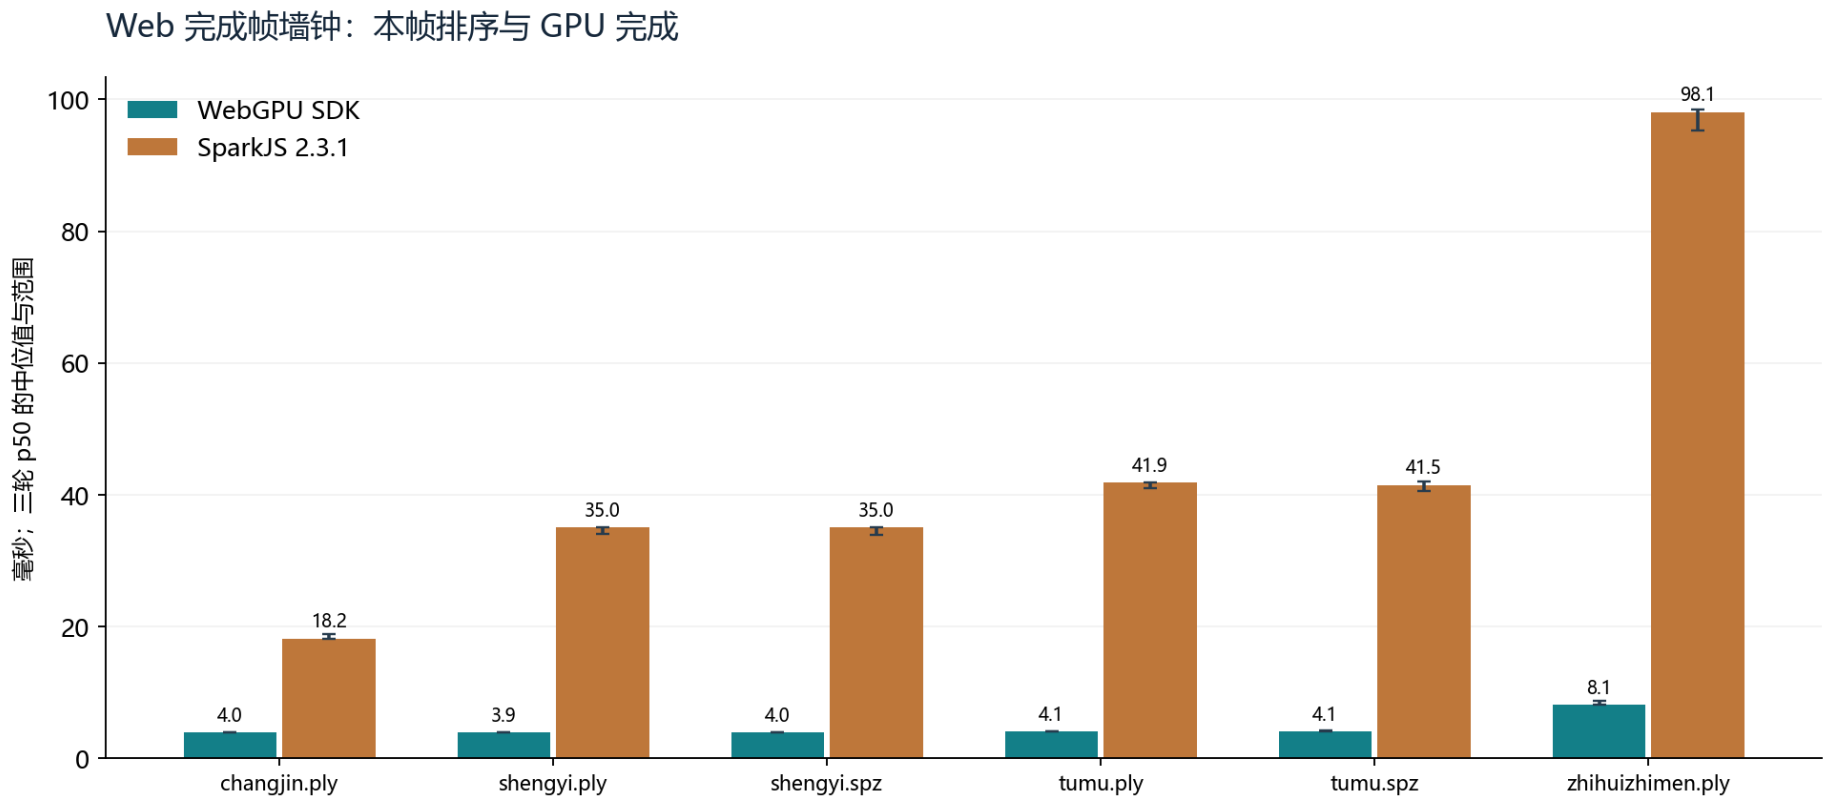
Web完成帧p50约3.9-8.1ms，Spark约18.2-98.1ms；差异属于此串行完成协议。Spark显式update等待Worker排序、保持默认readPause，检查sortedCenter与当前相机，绘制后gl.finish并等待本帧WebGL timer可用。Web等待对应WebGPU队列和timestamp map，同一gpuFrameId核验。两边都可能受到浏览器IPC、timer观察和读回下限影响。[S16/S19]

updateMs包括Spark更新驱动、异步Worker排序、深度读回、默认暂停与提交调度，不能改名成“Rust排序时间”。没有测物理扫描、motion-to-photon、普通自动rAF并行吞吐或动态逐像素透明顺序误差。391万点前景质量差异也使其不能作为等画质发布门槛通过。

Windows没有同一个串行运动相机/首排序/完成帧墙钟协议。其GPU表只能诊断并列，不能与本表计算整体速度或FPS倍数。早期无节流回调吞吐和30分钟稳定性与本轮六组不是同一次实验。

Web / Spark：完成帧对照图

当前相机排序 + 本帧GPU完成；不等于屏幕真实FPS



1920×1080 / 全点 / SH3。完成帧包含 Worker update、timer 观察和同步等待；不是物理显示 FPS。

图9：三轮p50的中位值与范围。柱高包含update、timer观察与同步等待，不能解释为纯GPU成本。[S16]

11 / 解码、投影、排序、绘制：阶段对照

独立kernel没有测量就留空，不用总帧或update去推算

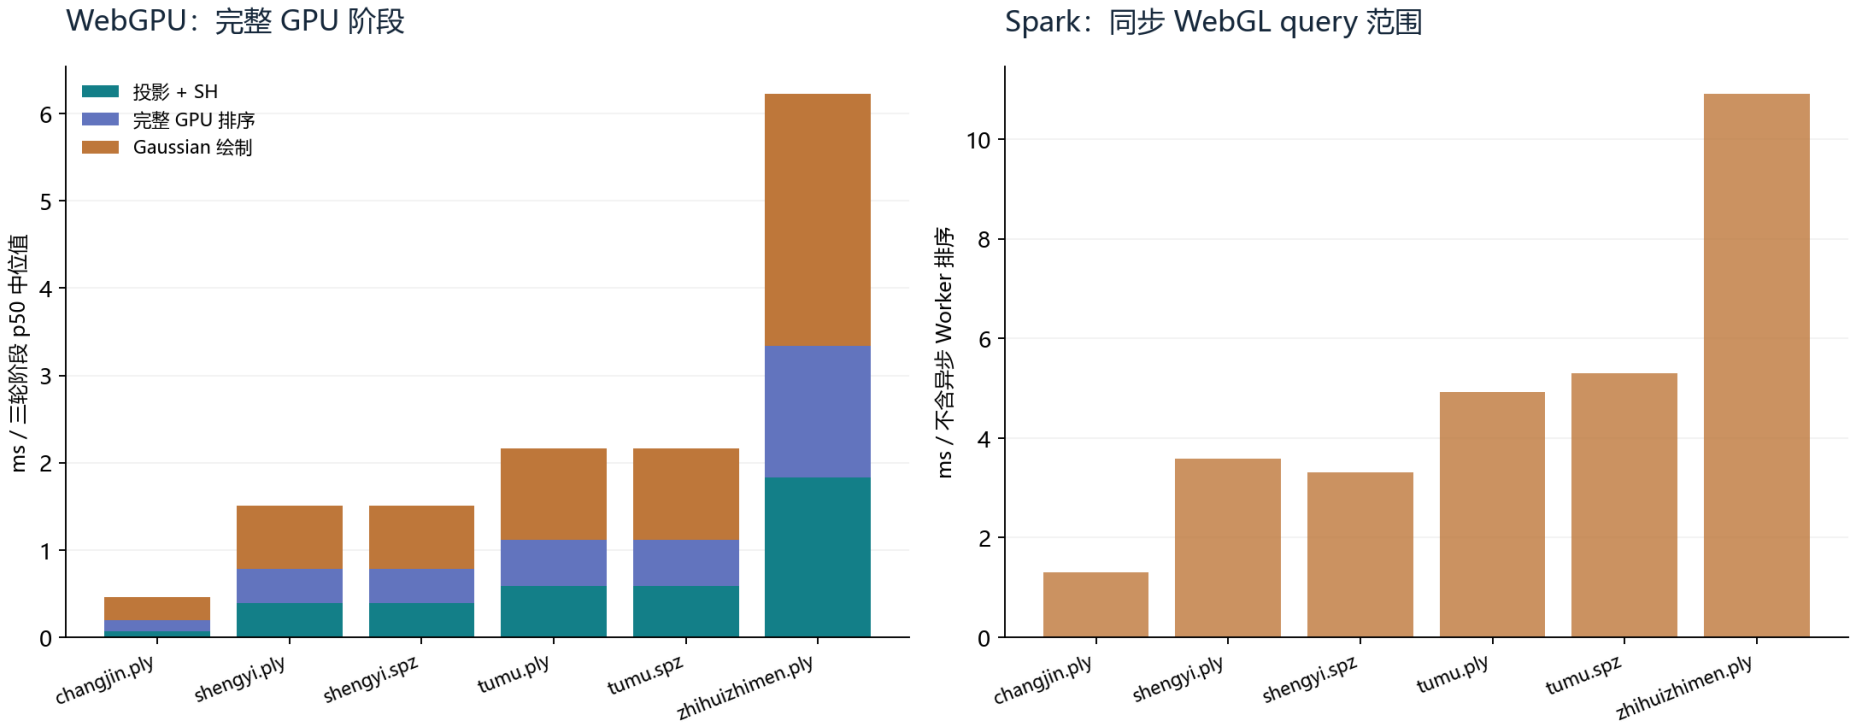
平台 / 引擎	解码 / 验证	投影 + SH	排序	渲染 / 绘制	整帧范围
Windows D3D12	load_ms，含文件/进程/解压/验证	独立GPU timestamp	独立GPU timestamp	独立GPU timestamp	GPU阶段和；无Present
Web SDK	38模型Decoding阶段墙钟；SPZ Inflating单列	独立WebGPU timestamp	完整全局radix timestamp	独立WebGPU timestamp	gpuMs与completedMs分开
SparkJS 2.3.1	无独立纯decode计时；首帧为完整链路	未单独计时	未单独计时；update非纯sort	同步WebGL query为合并范围	gpuMs不含异步Worker sort

模型	Web投影	Web排序	Web绘制	Web完整GPU	Spark同步GPU	Spark update墙钟
changjin_v1.ply	0.066	0.131	0.262	0.524	1.297	13.1
shengyi_v1.ply	0.393	0.393	0.721	1.442	3.587	24.5
shengyi_v1.spz	0.393	0.393	0.721	1.442	3.320	24.6
tumu_v1.ply	0.590	0.524	1.049	2.359	4.918	30.2
tumu_v1.spz	0.590	0.524	1.049	2.359	5.294	30.2
zhihuizhimen.ply	1.835	1.507	2.884	6.488	10.910	76.8

单位ms，GPU列为三轮阶段p50的中位。Spark同步gpuMs可包含同步生成accumulator/绘制中的GPU工作，但不是projection/sort/draw独立计时，也不包含全部异步排序成本。Windows load、Web Decoding 与Spark initialized不能视为相同纯decode任务。

GPU计时范围：完整流水线与同步 WebGL

通过不同面板显示不同 scope，避免误导性的整帧胜负图



两面板 query scope 不同。阶段 p50 的和不一定等于整帧 p50；Spark 投影 / 排序未独立计时。

图10：左侧为WebGPU完整三阶段；右侧为Spark同步WebGL query。不是等范围GPU整帧比较。[S16/S19]

12 / 2248 万点：完整加载阶段

使用最终发布源码38模型套件；本次未重新运行全38模型 [S13/S14]

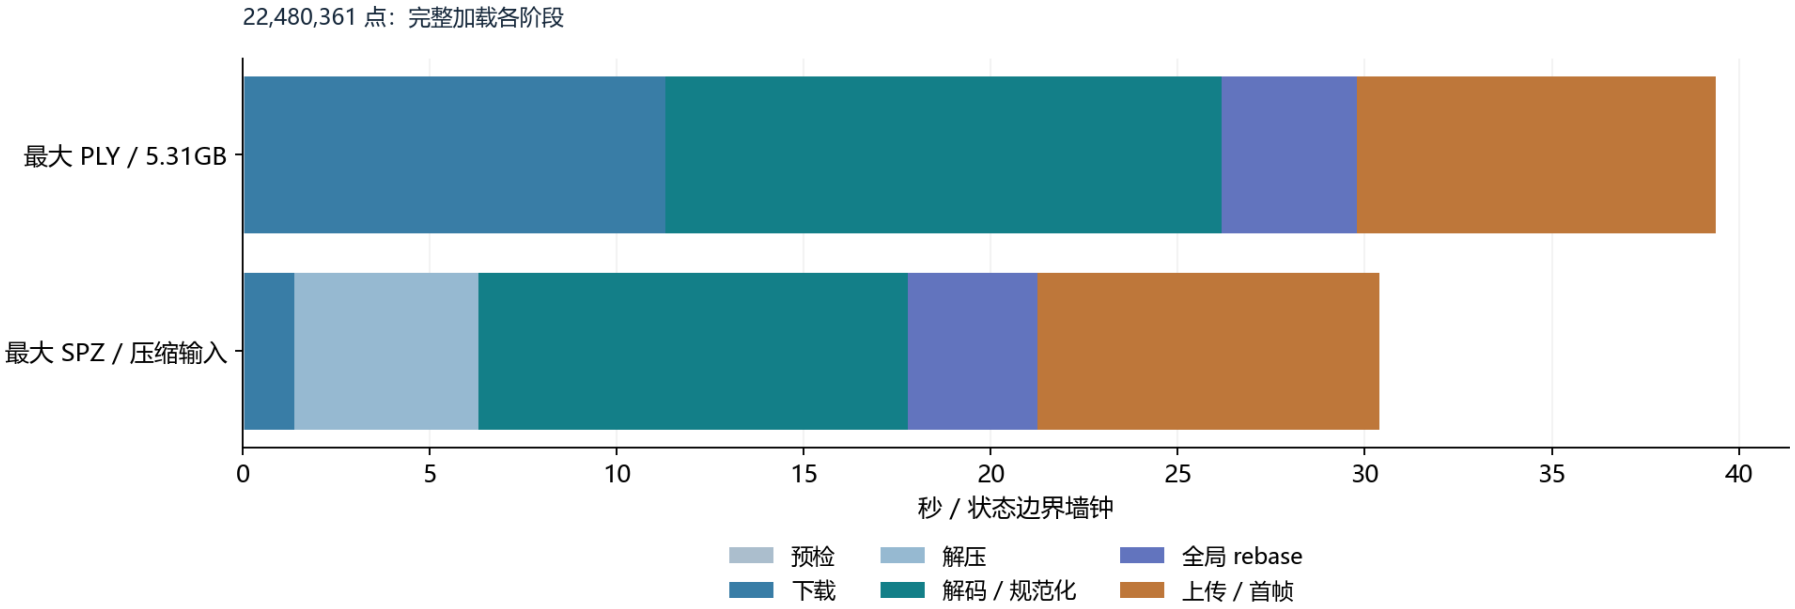


图11：最大PLY/SPZ完整加载的状态边界墙钟。保留全点SH3，不把OPFS I/O计作纯解码kernel。

22,480,361点 / SH3	下载	解压	解码/规范化	全局rebase	上传/首帧	完整加载 / 另计清理
jiulonghu_v1.ply	11,262.3	不适用	14,877.2	3,609.5	9,598.3	39,381.4 / 513.9
jiulonghu_v1.spz	1,329.5	4,928.1	11,479.5	3,471.8	9,137.8	30,382.4 / 504.1

最大模型：GPU瓶颈与资源容量

Windows新增诊断与Web发布完成帧证据分别列出，条件不可互换

引擎 / 条件	投影+SH	稳定排序	绘制	GPU总帧	完成帧墙钟
Windows PLY / 固定相机force / 本次	10.470	8.091	16.009	34.633	未记录
Web SPZ / 120运动姿态 / 发布轮1	11.993	9.241	17.039	38.404	41.1
Web SPZ / 120运动姿态 / 发布轮2	11.534	9.175	17.105	38.339	40.3
Web SPZ / 120运动姿态 / 发布轮3	10.945	8.782	15.991	35.914	38.0
Spark最大同协议	未测	未测	未测	未测	未测

Web最大SPZ GPU p50为38.404/38.339/35.914ms，完成墙钟41.1/40.3/38.0ms，独立首帧29.656秒。Windows本次大PLY GPU p50三轮中位约34.633ms。由于格式、相机轨迹、时间、同步与query机制不同，不用二者计算Web相对Windows的百分比。[S04/S15]

两端都已经把最大模型从容量失败推进到完整可加载。当前Windows与Web全动态路径都受投影、排序、绘制共同约束：Web绘制约16-17ms，Windows约16ms，继续只减少加载过程或小模型排序不足以改善最大模型持续帧。可见集合压缩需要先确认裁剪率；此Windows大样本此前记录全部点进入绘制，不能假设压缩一定收益。

Web最大场景GPU分配约6.58GB、backing约5.31GB；默认8GiB预算不保证剩余VRAM。Web资源不足显式拒绝；Windows可显式降低质量，但降质结果不能混进全SH3比较。“任何电脑完整渲染”没有无条件实测保证。

13 / 性能优化：已验证的收益与被撤回的尝试

容量、阶段和完整帧各自有证据；不把一个指标的变化当作所有指标的收益

平台 / 改动	证据中的变化	判断与范围
Windows 64MiB copy页	大SH3上传约20.3→1.5秒	保留；CPU解码仍约10秒；不代表GPU帧加速
Windows radix调度 + SH展开 + 4顶点带	当时完整GPU帧约41.7→33.4-33.8ms	保留；本次新诊断34.633ms，非完全同一实验
Windows 40B投影结构	大模型约减少180MB	容量收益；无独立帧时间收益声明
Web lane bitmap / popcount rank	804k键1.835→0.393ms；1.25m键2.884→0.524ms	稳定性/正确性参考通过；真实帧仍看整体
Web专门化与64点tiled布局	804k投影2.490→0.393ms；1.25m约4.26-4.46→0.590ms	相同cloud/相机，三轮交错；固定图像hash一致
Web完整布局GPU帧	804k约3.998→1.442-1.507ms；1.25m6.160→2.228ms	约62-64% GPU改善；不推算网站FPS
Web OPFS + bounded WASM	最大点数2248万；38/38完整成功	容量/可取消/恢复收益；多遍I/O增加首载成本
Android subgroup scatter	排序均值三轮中位34.98→17.84ms	热态不等价；Mobile 30FPS仍未达成
Cloud 可重建缓存与WAL NORMAL	历史Windows miss p50 220.656→74.182ms	20样本等相机HTTP诊断；不含屏幕呈现

来源：Windows S03、Web S13/S21、Android S08、Cloud S10。Web 8-bit radix没有可靠完整帧收益，保留4-bit默认；Windows的无收益改写和更大上传页已撤回。Spark LoD/量化可能减少当帧工作，但本报告的全点基线关闭LoD，不能把删点/降SH当作同质量算法优化。

14 / 静态画质验证与比较限制

18个视角 / 6组模型；全图与前景指标同时报告 [S17]

模型 / 默认、左、右三个视角	最低全图SSIM	最低前景SSIM	前景MAE范围 / 0-255
changjin_v1.ply	0.996856	0.992675	0.922-1.019
shengyi_v1.ply	0.998783	0.996223	2.510-2.659
shengyi_v1.spz	0.999529	0.998305	0.703-0.802
tumu_v1.ply	0.999453	0.997247	1.569-1.606
tumu_v1.spz	0.999383	0.997165	0.901-1.060
zhihuizhimen.ply	0.997262	0.986509	6.782-7.136

全图最小SSIM为0.996856，前景最小为0.986509。391万点zhihuizhimen的前景MAE约6.78-7.14/255，高于其他组；大面积黑背景会抬高全图SSIM。该现象应在局部颜色、SH、opacity、预模糊与排序等因素上进一步隔离，当前证据不能确定单一根因。

本轮配置名义一致、同一输入文件与相机，但不能直接称“全套完全等画质”。六组性能数据有效，391万点的新增画质差异必须与性能结论一起披露。固定图像比较没有验证运动过程的透明排序新鲜度、物理显示、抗锯齿或所有极端各向异性。Windows本次未做与Spark的固定视角SSIM，Windows内部图像回归不能替代跨引擎质量对照。

PLY和SPZ相同点数不等于原始属性逐值一致。对照按同一文件SHA分别运行，不把PLY/SPZ的压缩量化差异解释成某一个引擎的精度损失；上述MAE也不能直接当GPU性能归因。

15 / SparkJS：Rust/WASM与可借鉴的组织方式

源码研究与已安装 benchmark 包分开标识 [S18]

基准包为@sparkjsdev/spark2.3.1；源码研读固定于upstream commit f5368253780bed4d863c96b1fdea9dd3d614d131（MIT）。upstream main的结构不证明已安装WASM二进制每一个路径相同，不能把研究代码当作本轮性能证据。

层 / 组件	组织与机制	本仓库可借鉴内容
TypeScript SplatLoader / SplatMesh	SplatWorker RPC与队列；可转移缓冲；复用WASM初始化	任务identity、进度/错误契约；复用前先保证可取消/清理
spark-rs / wasm-bindgen	ChunkDecoder.push；thread-local输入Vec；每次JS拷贝≤1MiB	小边界批次，避免整输入与整规范化场景重复驻留
spark-lib / 格式解析	ChunkReceiver / SplatReceiver；PLY头部字段预编译	decoder与renderer分层；字段访问在点循环前准备
SPZ流式解压	列属性状态机；128KiB输出与32KiB滑动历史	有界解压、复用缓冲；ForWeb选择OPFS列页
compact representation	部分opacity f16与RGB/scale/rotation u8	更小带宽，但需显式精度/画质档，不冒充float32等价
tiny_lod / bhatt_lod / chunk_tree	解码后独立建树；Morton/网格/约65536节点批次	页标识、包围盒与独立预处理器；LoD另定误差契约

ForWeb已采用批次上限、字段预编译、输入输出职责分离、流式解压和局部性原则，没有复制Spark源码或改写第二套Rust解码器。其C++/WASM继续复用native规范化和vendor SPZ unpack数学。Rust与C++公平速度比较还需相同任务/存储/量化策略，分别测JS拷贝、pure decode、normalize、pack、建树、upload与首帧；当前没有这样的语言对照。

16 / 验收状态与后续改进优先级

保持已有通过项，也保留真实未完成的质量与设备门槛

领域	已验证	仍待验证 / 下一步
Windows	完整大PLY、D3D12阶段、排序/图像回归、PIX有效事件	同Spark的同轨迹/同质完成帧；真实低显存/跨厂商/PresentMon
Android	C ABI/AAR、隔离解码、Adreno真机、分段/subgroup	严格等热态重复、Mobile30FPS、SSIM/低内存/多驱动
Web	36CPU+18契约、GPU/联合/SDK、38全模型；100次+5分钟	新增391万点前景差异；跨平台；实际显示；SIMD/LoD/cloud
Cloud	当前v3/0.2.2、缓存/实例/真实lease恢复、安装与静置	公网TLS/RBAC、WAN/长期负载、全38模型、外部编排重启
本次报告补测	Windows21进程、Web12组、18静态视角	首载仅单次；Spark独立解码/投影/排序kernel未采集

推荐的下一轮顺序

P0 先隔离391万点样本的前景颜色/SH/opacity差异，补相同相机的Windows/Spark静态与动态质量条件。P1 定义统一首帧边界和GPU完成帧协议：把Windows设备初始化、上传、首次排序/绘制及Present分开；Spark在Worker与WASM边界补稳定stage instrumentation。P2 针对Web首载，消融中型内存快路径、直接decode-to-packed和有状态可取消Worker复用，保留峰值与迟到事务测试。

P3 对最大模型重点优化绘制及输入局部性，测近景/重叠/裁剪率；动态可见集合、SH存储压缩和LoD分别给出画质契约。P4 Android按thermal0完整三轮与显示帧验收；Cloud测真实移动/WAN预测命中率与端侧解码负载。不得用更少点数、更低SH、降分辨率或更宽松测试替代约定质量门槛。

本报告没有修改引擎算法，也没有重新发布SDK、推送或合并PR。新增图表、数据和报告属于本地报告工作；原先发布资产的source commit与SHA仍有效。

附录 A / PLY 完整加载阶段表

38模型发布套件的PLY部分；单位ms；输入MiB；完整点数与SH3 [S14/S20]

模型	点数	MiB	加载	预检	下载	解压	解码	rebase	上传/首帧	清理
changjin_v1.ply	170,799	38.4	449.7	30.9	205.0	-	92.3	45.4	76.1	6.9
citang_v1.ply	2,116,317	476.3	3,933.2	28.1	1,177.9	-	1,373.7	499.9	853.5	48.8
danganguan_v1.ply	1,888,950	425.1	3,547.7	37.2	1,153.0	-	1,087.1	381.7	888.6	45.1
haiwai_v1.ply	1,838,109	413.7	3,658.9	33.6	1,180.7	-	1,194.0	383.6	867.0	49.7
he_v1.ply	2,973,002	669.1	5,599.7	31.7	1,676.8	-	1,936.4	600.7	1,354.0	72.8
J1_v3.ply	2,625,008	590.8	5,070.7	34.3	1,531.5	-	1,646.6	542.2	1,316.0	66.2
jiaoxuelou_v2.ply	2,233,426	502.7	4,349.8	37.2	1,377.7	-	1,447.9	458.4	1,028.5	57.0
jiulonghu_v1.ply	22,480,361	5,059.6	39,381.4	34.0	11,262.3	-	14,877.2	3,609.5	9,598.3	513.9
jizhonglou_v2.ply	1,576,115	354.7	3,207.6	49.0	1,050.1	-	1,040.3	344.2	723.7	42.0
juyuan_v2.ply	2,670,017	600.9	5,343.5	36.7	1,592.1	-	1,832.3	606.1	1,276.2	65.7
meiyuan_v2.ply	1,312,897	295.5	2,605.4	35.6	810.2	-	853.8	275.8	630.0	38.8
PML_v1.ply	851,828	191.7	1,729.9	33.0	567.7	-	556.7	177.5	395.0	23.2
shengyi_v1.ply	804,758	181.1	1,747.6	32.9	525.9	-	601.2	198.5	389.0	25.0
tiyuguan_v1.ply	1,419,007	319.4	2,772.6	29.9	845.4	-	917.0	309.6	670.5	37.3
tumu_v1.ply	1,248,730	281.0	2,475.6	35.5	806.5	-	790.1	267.8	575.6	30.7
tushuguan_v1.ply	1,438,782	323.8	2,802.1	37.7	840.9	-	921.0	294.2	708.3	40.4
wenke_v2.ply	1,757,157	395.5	3,579.0	35.0	1,130.4	-	1,162.8	401.5	849.3	42.7
xingxi_v1.ply	1,307,854	294.4	2,551.1	36.8	809.7	-	833.2	271.6	599.8	39.6
yulin_v1.ply	1,027,833	231.3	2,000.9	34.1	648.5	-	638.2	218.3	461.7	27.7
zhihuizhimen.ply	3,914,609	881.1	7,534.5	33.2	2,275.9	-	2,669.3	815.3	1,740.8	93.1
zhishan_v3.ply	649,520	146.2	1,275.8	36.2	448.1	-	401.5	137.4	252.6	18.7

21个PLY，全部result.ok=true；加载不含清理。这些是单次逐模型功能/容量测量，不是重复加载基准；Decoding不是pure WASM kernel，Uploading包含首帧GPU完成与呈现。GPU帧不是每模型都测量，不能从加载时间推导帧时间。

附录 B / SPZ 完整加载阶段表

38模型发布套件的SPZ部分；单位ms；解压单列；完整点数与SH3 [S14/S20]

模型	点数	MiB	加载	预检	下载	解压	解码	rebase	上传/首帧	清理
citang_v1.spz	2,116,317	40.5	3,468.8	38.0	286.4	596.1	1,140.5	409.6	998.1	39.0
danganguan_v1.spz	1,888,950	33.6	2,818.2	34.8	204.8	442.4	911.2	364.6	860.4	47.6
haiwai_v1.spz	1,838,109	34.8	2,776.0	33.1	230.9	435.1	872.7	365.9	838.3	44.9
he_v1.spz	2,973,002	48.7	4,240.9	33.1	230.3	612.1	1,430.0	558.9	1,376.4	59.6
J1_v3.spz	2,625,008	47.3	3,896.0	33.3	301.3	603.4	1,250.8	509.0	1,198.2	54.7
jiaoxuelou_v2.spz	2,233,426	43.4	3,326.7	33.9	229.3	527.0	1,090.4	431.8	1,014.3	51.7
jiulonghu_v1.spz	22,480,361	477.6	30,382.4	35.6	1,329.5	4,928.1	11,479.5	3,471.8	9,137.8	504.1
jizhonglou_v2.spz	1,576,115	32.7	2,411.6	44.3	275.1	408.3	744.7	316.6	622.6	38.4
juyuan_v2.spz	2,670,017	50.2	4,014.7	33.9	263.1	630.5	1,297.0	540.0	1,250.2	58.5
meiyuan_v2.spz	1,312,897	25.4	2,036.3	32.8	190.8	331.7	617.9	263.7	599.4	36.3
shengyi_v1.spz	804,758	17.1	1,376.2	38.9	180.6	236.4	379.7	172.1	368.5	24.0
tiyuguan_v1.spz	1,419,007	26.5	2,245.8	33.2	196.1	361.0	697.7	291.3	666.4	33.7
tumu_v1.spz	1,248,730	23.3	1,963.3	30.3	206.2	310.1	587.8	259.7	569.1	34.0
tushuguan_v1.spz	1,438,782	28.1	2,185.0	32.4	175.4	354.2	683.8	281.7	657.5	31.9
wenke_v2.spz	1,757,157	35.7	2,834.6	33.0	197.2	465.0	912.4	341.9	885.1	41.5
xingxi_v1.spz	1,307,854	25.2	1,864.8	32.4	163.5	318.1	591.8	253.2	505.7	29.6
yulin_v1.spz	1,027,833	20.0	1,523.6	32.5	144.9	252.4	454.3	197.5	441.9	25.3

17个SPZ，全部result.ok=true；加载不含清理。这些是单次逐模型功能/容量测量，不是重复加载基准；Decoding不是pure WASM kernel，Uploading包含首帧GPU完成与呈现。GPU帧不是每模型都测量，不能从加载时间推导帧时间。

附录 C / 配对模型身份与复现

输入文件不分发；只保留名称、字节、点数与SHA256

文件	字节 / 点数	SHA-256
changjin_v1.ply	40,310,041 B / 170,799点	7c7cb96bed46540483fdd488544dab77a6bf512d97621f1d6b02334793637b83
shengyi_v1.ply	189,924,365 B / 804,758点	31283b07ef49679b5fbe8854669a7a2d948e9cbf76795d4ae4d3057f86683d79
shengyi_v1.spz	17,927,619 B / 804,758点	fd7af1e635b7932fc1fc9a19b2c69606c51a5be0b14ecd62f3fabf9479ca2866
tumu_v1.ply	294,701,758 B / 1,248,730点	2b82a22a97254d2d3375f669e4da15ff8d639da0169c28297a1ce777e9d3c7f9
tumu_v1.spz	24,412,867 B / 1,248,730点	c2296c3500dadd3fe56efb76e984f09fd903f04f676a5e71d4d902a819278167
zhihuizhimen.ply	923,849,202 B / 3,914,609点	d86fa4be8a412f3b78169ccb3dd25044397fb1d2dd3f275c27497b6b39d3a669

本次新增数据的复现命令

Windows（仓库根）：python docs/reports/native3dgs-2026-10-04/measure_windows.py。它只运行已有out/Release/Native3DGSViewer.SceneBench.exe，记录完整命令、日志、SHA、120帧样本和失败状态；若要验证新源码二进制，应先按仓库规则重新构建，另建证据记录。

Web：在ForWeb目录设置GS_MODEL_ROOT并运行pnpm run dev；另一个终端设置GS_BENCH_MODELS为附表六个相对模型路径，GS_BENCH_OUTPUT=../docs/reports/native3dgs-2026-10-04/evidence/web-paired，运行node tools/completed-benchmark.mjs；之后python tools/image-metrics.py <该输出目录>。所有GPU测试顺序执行；不要在浏览器长测期间改ForWeb/src或触发HMR。

图表：系统Python（matplotlib/Pillow）运行figures.py。PDF/Markdown：使用Codex bundled Python（ReportLab/Pillow/pypdf）运行build_report.py。输出附windows-stages.csv、web-paired-summary.csv、model-load-stages.csv与report-manifest.json；所有摘要从原始数据重新计算，不手工改图。

证据索引 / 架构、原生与Cloud

所有项目都对应实际本地文件；历史证据仅用于其标识日期和协议

编号	用途	仓库相对路径
S01	Windows 总体方案与模块边界	docs/system-technical-design.md
S02	Windows SDK 事务、相机与 Surface 契约	docs/SPEC-engine-sdk.md
S03	Windows 2026-09-30 优化/PIX 诊断	docs/windows-performance-verification.md
S04	Windows 本次 7 模型/21 进程诊断	docs/reports/native3dgs-2026-10-04/evidence/windows-diagnostics.json
S05	Windows 基准源代码与计时范围	bench/scene.cpp
S06	Android 系统架构	ForAndroid/docs/system-technical-design.md
S07	Android 当前 SDK 与能力边界	ForAndroid/docs/SDK-guide.md
S08	Adreno 750 真机性能与大模型	ForAndroid/docs/verification/device-performance-2026-09-30-adreno750.md
S09	Cloud 当前 CUDA/Go/缓存架构	ForServer/docs/architecture.md
S10	Cloud API v3 缓存延迟证据（历史基准）	ForServer/docs/verification-instances-v3.md
S11	Cloud 0.2.2 当前修订验收	ForServer/docs/verification-cloud-022.md

报告文件包：native3dgs-engine-report-2026-10-04.pdf为排版版，报告目录内report.md为可编辑正文，figures/内PNG为预览、SVG为独立矢量图，evidence/为原始与派生性能数据。原始RGBA是质量分析中间文件，不是模型资源，也不纳入图形交付ZIP。

证据索引 / Web、Spark与计时原始数据

所有项目都对应实际本地文件；历史证据仅用于其标识日期和协议

编号	用途	仓库相对路径
S12	Web 实际 API 和部署契约	ForWeb/docs/SDK-guide.md
S13	Web 最终完整大模型/布局/稳定性报告	ForWeb/docs/verification/large-model-optimization-report.md
S14	Web 完整 38 模型的阶段计时	ForWeb/docs/verification/evidence/model-tests-release.json
S15	Web 最大模型 GPU 完成帧	ForWeb/docs/verification/evidence/maximum-completed-frame.json
S16	本次 Web/Spark 六模型配对结果	docs/reports/native3dgs-2026-10-04/evidence/web-paired/results.json
S17	本次 18 固定视角质量对照	docs/reports/native3dgs-2026-10-04/evidence/web-paired/image-quality.json
S18	Spark Rust/WASM/LoD 固定提交研读	ForWeb/docs/verification/spark-decoder-source-study.md
S19	Web 原始计时与 Spark 更新驱动	ForWeb/apps/benchmark.ts
S20	Web 38 模型名称、尺寸、点数与 SHA	ForWeb/docs/verification/evidence/model-manifest.json
S21	Web 布局消融原始数据	ForWeb/docs/verification/evidence/layout-ablation.json
S22	Web OCR 六轮处置与局限	ForWeb/docs/verification/ocr-review-report.md

报告文件包：native3dgs-engine-report-2026-10-04.pdf为排版版，报告目录内report.md为可编辑正文，figures/内PNG为预览、SVG为独立矢量图，evidence/为原始与派生性能数据。原始RGBA是质量分析中间文件，不是模型资源，也不纳入图形交付ZIP。